

# INTEGRITETSBEVARANDE NÄRVARODETEKTERING MED WIFI-RSSI

Högskoleingenjörsutbildning i Datateknik  
Cybersäkerhet och digitalinfrastruktur

Anton Wolter  
Elliot Persson



HÖGSKOLAN I BORÅS

**Program:** IT-ingenjör - Digitalinfrastruktur och cybersäkerhet

**Svensk titel:** Integritetsbevarande närvarodetektering med WiFi-RSSI

**Engelsk titel:** Integrity-preserving presence detection with WiFi-RSSI

**Författare:** Anton Wolter, Elliot Persson

**Nyckelord:** Närvarodetektering, WiFi-RSSI, Integritetsbevarande, Isolation Forest, Dataminimering

---

## Sammanfattning (svenska)

Arbetet undersöker hur närvaro i en datalabbsal kan detekteras genom RSSI förändringar mellan en WiFi router och fem omodifierade, kommersiellt tillgängliga IoT enheter (fyra smarta uttag och en LED-slinga), utan att kompromissa med personlig integritet. Systemet är konstruerat enligt principen privacy by design, ingen bild eller ljudinformation samlas in i det driftsatta systemet, och rå RSSI data lämnar aldrig det lokala nätverket. Endast aggregerade närvaroperioder vidarebefordras till Azure IoT Hub för fjärrvisualisering i Power BI, vilket möjliggör att rumsutnyttjandet kan följas på distans utan att utöka mängden persondata.

En hybridmodell av regelbaserade detektorer och en oövervakad Isolation Forest anomalidetektor utvärderades genom offline replay mot 164 631 sampelpunkter över 20 dygn (28 april till 17 maj 2026), med en kamera som facit. Modellen fångar aktiv närvaro snabbt, med en sample-true-positive-rate (TPR) på 67,8 % och en medianlatens på 2,6 minuter (max 34,7). Fyra av nio manuellt annoterade närvarofönster fångades. Fyra av de fem missade fönstren var stillasittande sessioner i en svag signalzon där rummet statistiskt var oskiljbart från ett tomt rum, en fysisk gräns som drabbar både WiFi-RSSI och kameran. Falsklarmen var få, noll under samtliga nattperioder över 20 dygn.

Projektet inleddes med ambitionen att modellen skulle styra labbsalens belysning i realtid. Den empiriska utvärderingen visade att täckningen mot stillasittande närvaro är ofullständig på ett sätt som gör realtidsstyrning olämplig, och projektets fokus omformulerades därefter till en tillbakablickande närvarologg som huvudprodukt. Belysningen behölls som ett lokalt funktionsbevis. Resultaten visar att lösningen är bäst lämpad som datadrivet underlag för rumsutnyttjandeanalys, en användning där både integritetsskyddet och den tillförlitliga detektionen av aktiv närvaro kommer till sin rätt.

## **Abstract (Engelska)**

This thesis investigates how occupancy in a university lab room can be detected through RSSI fluctuations between a WiFi router and five unmodified, commercially available IoT devices (four smart plugs and an LED strip), without compromising personal privacy. The system is built according to the principle of privacy by design, no image or audio data is collected in the deployed system, and raw RSSI data never leaves the local network. Only aggregated occupancy periods are forwarded to Azure IoT Hub for remote visualisation in Power BI, enabling room usage to be monitored remotely without expanding the amount of personal data collected.

A hybrid model combining rule-based detectors with an unsupervised Isolation Forest anomaly detector was evaluated through offline replay against 164,631 sample points over 20 days (28 April to 17 May 2026), using a camera as ground truth. The model detects active occupancy quickly, with a sample-level true positive rate of 67.8% and a median detection latency of 2.6 minutes (max 34.7). Four out of nine manually annotated presence windows were captured. Four of the five missed windows were sedentary sessions in a weak-signal zone where the room was statistically indistinguishable from an empty room, a physical limit shared by WiFi-RSSI and the camera. False alarms were few to zero during overnight periods across all 20 days.

The project began with the ambition that the model would control the lab's lighting in real time. The empirical evaluation showed that coverage against sedentary occupancy is incomplete in a way that disqualifies real-time control, and the project's focus was therefore reformulated to a retrospective occupancy log as the main deliverable. Lighting was retained as a local proof of function. The results indicate that the solution is best suited as a data-driven basis for room-usage analysis, an application in which both the privacy protection and the reliable detection of active occupancy are used to their full potential.

## Innehållsförteckning

|                                              |           |
|----------------------------------------------|-----------|
| <b>1. INLEDNING.....</b>                     | <b>1</b>  |
| 1.1 Problemställning & Syfte .....           | 1         |
| 1.2 Avgränsningar .....                      | 2         |
| <b>2. TEORI.....</b>                         | <b>3</b>  |
| 2.1 Bakgrund och fysikalisk princip.....     | 3         |
| 2.2 RSSI kontra CSI och energibesparing..... | 3         |
| 2.3 Kunskapslucka.....                       | 4         |
| <b>3. METOD.....</b>                         | <b>5</b>  |
| 3.1 Undersökningsdesign .....                | 5         |
| 3.2 Mätuppställning och hårdvara.....        | 5         |
| 3.3 Datainsamling.....                       | 5         |
| 3.4 Annotering och ground truth .....        | 6         |
| 3.5 Detektionsmodell och träning.....        | 6         |
| 3.6 Utvärdering .....                        | 6         |
| 3.7 Live-drift och dataflöde .....           | 7         |
| 3.8 Användning av AI-verktyg.....            | 7         |
| <b>4. RESULTAT.....</b>                      | <b>9</b>  |
| 4.1 Utvärderings uppställning.....           | 9         |
| 4.2 Detektionsförmåga .....                  | 9         |
| 4.3 Falsklarm.....                           | 10        |
| 4.4 Detektorernas bidrag .....               | 10        |
| 4.5 Effekt av baseline-drift-åtgärden.....   | 10        |
| 4.6 Närvaroperioder och tidsbias .....       | 11        |
| 4.7 Täckningsområde.....                     | 11        |
| <b>5. DISKUSSION .....</b>                   | <b>12</b> |

|            |                                     |           |
|------------|-------------------------------------|-----------|
| <b>5.1</b> | <b>Svar på frågeställning .....</b> | <b>12</b> |
| 5.1.1      | Fråga 1 .....                       | 12        |
| 5.1.2      | Fråga 2 .....                       | 12        |
| 5.1.3      | Fråga 3 .....                       | 13        |
| 5.1.4      | Fråga 4 .....                       | 13        |
| <b>5.2</b> | <b>Slutsats.....</b>                | <b>14</b> |
| <b>5.3</b> | <b>Vidare forskning .....</b>       | <b>14</b> |
| <b>6.</b>  | <b>REFERENSER.....</b>              | <b>16</b> |
| <b>7.</b>  | <b>BILAGOR .....</b>                | <b>17</b> |

# 1. INLEDNING

Det globala antalet anslutna IoT enheter har växt kraftigt under det senaste decenniet, och en stor del av denna tillväxt sker i kontor, utbildningslokaler och bostäder där smarta uttag, lampor och miljösensorer används för komfort, energistyrning och fjärrövervakning. Parallellt har EU:s dataskyddsförordning (Europaparlamentet och rådet, 2016) och en växande medvetenhet om digital integritet skapat ett tryck på att den datainsamling som följer av IoT-system ska begränsas till det ändamålet kräver.

Detta samhällsklimat ställer nya krav på de tekniker som används för att automatisera lokaler, Smart belysning, ventilation och rumsbokningssystem behöver veta om ett rum är bemannat, vilket traditionellt löses med kameror eller PIR-sensorer. Kameror möjliggör avancerad detektion men medför hantering av bilder som klassas som personuppgifter, vilket i sin tur kräver en rättslig grund, tekniska skyddsåtgärder och informationsplikt. PIR-sensorer är integritetsmässigt enklare men kräver dedikerad hårdvara i varje rum, missar stillasittande personer och bidrar till elektroniskt avfall när de byts ut.

Samtidigt visar forskningen under det senaste decenniet att radiosignaler som ändå sänds av befintliga WiFi-enheter (i form av RSSI rapportering mot routern) bär information om människor som rör sig i rummet (Mrazovac, Bjelica, Kukolj, Todorović och Samardžija 2012; Li, Vishwakarma, Tang, Woodbridge, Piechocki & Chetty 2022; Miao, Huang, Lu, Ohtsuki, Gui & Sari 2025). Denna möjlighet är intressant både ur ett hållbarhetsperspektiv (återanvänd hårdvara, lägre energiförbrukning och mindre elektroniskt avfall) och ur ett integritetsperspektiv (inga bilder eller ljuddata produceras). Den här studien tar sin utgångspunkt i denna observation och undersöker hur långt en sådan lösning kan drivas i en realistisk datorlabbsal med blandad konsumenthårdvara.

## 1.1 Problemställning & Syfte

**Problemställning.** Tidigare studier har visat att RSSI från WiFi och Zigbee enheter kan användas för närvarodetektion med god precision (Mrazovac et al., 2012; Li et al., 2022). Flertalet av dessa studier bygger dock på antingen specialiserad hårdvara, modifierade firmware eller på CSI (Channel State Information) som inte är tillgänglig i konsumentprodukter. Frågan om hur långt man kommer med rå RSSI från omodifierade IoT enheter, som faktiskt finns installerade i de flesta lokaler idag, är mindre belyst. Dessutom är det oklart hur de utmaningarna som uppstår i en aktivt använd lokal (brusig RSSI, baseline ändringar från möbelflytt och städning, falska larm från korridortrafik) påverkar detektionsprestandan, och vilken avvägning mellan detektionsfördröjning och antal falska positiva som tvingas fram när systemet ska styra automation.

**Syfte.** Arbetets syfte är att utveckla och utvärdera ett närvarodetektionssystem som detekterar mänsklig närvaro i en labbsal genom RSSI förändringar från befintliga, omodifierade WiFi enheter mot en central router. Systemet ska konstrueras enligt principen privacy by design (varken bild eller ljudmaterial samlas in i den slutgiltiga lösningen) och bygga på redan installerad konsumenthårdvara för att hålla ekonomisk och ekologisk kostnad nere. Systemets huvudprodukt är en närvarologg som skickas till Azure IoT Hub och visas som statistik över hur labbsalen används i Power BI. Som synligt bevis på att systemet fungerar styr det dessutom en LED-slinga i labbsalen, som direkt visar personer i rummet att deras närvaro har upptäckts. Molnlösningen implementerades inte för den lokala funktionens skull (eftersom all detektion sker direkt på Raspberry Pi enheten) utan för att möjliggöra distansövervakning av hur rummet används. På detta sätt kan data avläsas utanför labbsalen utan att mängden persondata som

lämnar det lokala nätverket ökar. Under valideringsfasen används en kamera som ground truth, men denna exkluderas i det slutgiltiga systemet.

### Frågeställning

1. Hur väl kan en hybridmodell av regelbaserad stilladetektion och en oövervakad anomalidetektion med Isolation Forest klassificera *empty* respektive *occupied* i en labbsal med RSSI från en uppsättning omodifierade konsument IoT-enheter, mätt som true positive rate, antal falska alarm per dygn och detektionsfördröjning, med en kamerasensor som ground truth?
2. Vilken detektionsfördröjning krävs för att hålla antalet falska positiva på en acceptabel nivå givet den brusiga RSSI-signalen från omodifierad konsumenthårdvara, och hur påverkar den fördröjningen systemets användbarhet vid tillbakablickande närvarologgning respektive realtidsstyrning av belysning?
3. Hur skiljer sig de installerade ankarna åt med avseende på signalstabilitet och bidrag till detektionsprestanda, och hur kan deras placering och hårdvaruegenskaper kopplas till dessa skillnader?
4. I vilken utsträckning påverkas systemets prestanda av de miljöförändringar som uppstår i en aktivt använd labbsal (såsom möbelflytt efter föreläsningar, tillkommande föremål på bord och ommöbleringar av stolar mm) och hur väl kan en adaptiv baseline kompensera dessa förändringar.

## 1.2 Avgränsningar

- **Binär klassifikation.** Systemet avgör endast om rummet är bemannat eller tomt. Personräkning och positionering ligger utanför projektets omfattning, empirisk testning visade att RSSI vid 10 sekunders sampling inte räcker för att separera två mot tre personer eller fastställa position tillförlitligt.
- **En lokal.** Studien utförs i en labbsal vid Högskolan i Borås. Resultatens generaliserbarhet till andra planlösningar, möbleringar, materialval eller WiFi-miljöer undersöks inte.
- **Befintlig konsumenthårdvara.** Systemet bygger på en Asus RT-AC52U\_B1-router, fyra smarta uttag och en smart LED-slinga av tre olika fabrikat (Shelly, Clevero, Prokord) samt en Shelly H&T sensor, som fanns tillgängliga vid projektstart. Specialiserad hårdvara för CSI-rapportering, riktantennor eller dedikerade sensornoder ligger utanför avgränsningen.
- **Belysningsstyrning som funktionsbevis.** Modellen styr rummets belysning, men inte som slutprodukt. Belysningen fungerar som ett lokalt funktionsbevis (en indikator på att RSSI detektionen fångat närvaro) medan den primära slutprodukten är en tillbakablickande närvarologg.
- **Valideringsperiod.** Modellen utvärderas över cirka 20 dygns kontinuerlig data (28 april till 17 maj 2026) varav 13 oberoende dygn efter att träningsdatan ifrån helger utesluts. Plus manuella sessioner under våren 2026. Långtidsdrift över terminer eller årstider studeras inte.
- **Kameran som ground truth, inte en del av slutprodukten.** En Reolink kamera används enbart för att generera ground-truth anteckningar i träningsdata under valideringen. I det driftsatta systemet är kameran ej inkopplad och bidrar inte med live data till logg eller belysningsstyrning.
- **Säkerhets och kostnadsanalys** av Azure-pipelinan och MQTT flödet bearbetas ytligt.

## 2. TEORI

### 2.1 Bakgrund och fysikalisk princip

WiFi baserad sensing för närvarodetektion har under det senaste decenniet vuxit fram som ett integritetsbevarande alternativ till kameror och PIR sensorer. Tekniken utnyttjar att mänsklig närvaro förändrar radiosignalers utbredning på ett märkbart sätt (Miao et al. 2025). Till skillnad från kameror skapar WiFi signaler inte bilder, och till skillnad från PIR sensorer som enbart detekterar rörelse kan RF baserade metoder även upptäcka stillasittande personer.

Grunden demonstreras av Mrazovac et al. (2012) med fyra stationära Zigbee-noder (smarta uttag och strömbrytare) i ett bostadsenergisystem. Den mänskliga kroppen består till stor del av vatten vilket absorberar och sprider radiosignaler vid 2,4 GHz, vilket orsakar mätbara skillnader i signalstyrkan (RSSI). Genom att beräkna standardavvikelsen av RSSI över tidsfönster och jämföra mot trösklar är fastställda under tomma förhållanden uppnår systemet 98% precision i ett standardrum. I ett större rum sjunker precisionen till 84% vilket kopplas till blindfläckar bortom modernas räckvidd (Mrazovac et al., 2012). Trots att studien använder Zigbee snarare än WiFi använder sig båda protokollen av 2,4GHz bandet, vilket gör att tekniken fungerar på samma sätt och att resultaten går att överföra rakt av.

En central fråga för praktisk implementering är huruvida befintliga IoT-infrastruktur kan användas utan modifiering. Li et al. (2022) visar att det är möjligt med PiOTR (Passive IoT Radar), ett system som utnyttjar RF-sändningar från kommersiella IoT-enheter, så som Amazon Echo och Philips Hue utan att göra firmware ändringar. Systemet är protokolloberoende (WiFi, Zigbee, BLE) och uppnår en precision på 91% vid närvarodetektion. Li et al. betonar att tekniken är särskilt lämpad för integritetsmedvetna tillämpningar eftersom radiosignaler inte kan generera bilder (Li et al. 2022)

### 2.2 RSSI kontra CSI och energibesparing

I litteraturen finns en återkommande uppfattning att RSSI är otillräcklig för tillförlitlig närvarodetektion och att den mer detaljerade CSI-informationen (Channel State Information) krävs. Miao et al. (2025) noterar att RSSI är känslig för miljövariationer och flervägsstörningar, medan CSI beskriver amplitud och fas för varje underbärare i en OFDM signal och därmed erbjuder rikare kanalinformation. Denna kritik avser dock primärt system som använder råa RSSI värden.

Natarajan, Krishnasamy och Singh (2023) nyanserade bilden genom att visa statistiska features tagna från RSSI-tidsserier, varians MAD (Median Absolute Deviation), spännvidd och interkvartilspännvidd ger 92,9% precision för binär närvarodetektering. Systemet bygger på en ESP32 mikrokontroller som WiFi motagare modeller (Random Forest, XGBoost). Författarna identifierar en viktig skillnad: spridningsbaserade features (variens, MAD) indikerar närvaro, medan centralitetsbaserade features (medelvärde, median) snarare är rumsspecifika. Systemet är direkt kopplat till energistyrning med dokumenterade besparingar på upp till 66 % jämfört med fasta tidsscheman (Natarajan, Krishnasamy & Singh 2023)

I en uppföljande studie visar samma forskargrupp (Natarajan, Krishnasamy & Singh 2024) vad som blir möjligt med CSI. Med samma ESP32 plattform men 64 OFDM underbärare, Haar-wavelet-brusreducering och Gradient Boosting Classifier uppnår de 83,39% precision vid klassificering av fyra aktivitetsklasser (tomt, gående, sittande, stående). Systemet styr LED



Belysningen efter detekterad aktivitet med energibesparingar på 36% i kontorsmiljö och upp till 62% med dagsljuskörning (Natarajan, Krishnasamy & Singh 2024). Att precisionen är lägre än 92,9% beror på att uppgiften är svårare (fyra klasser mot två) inte på att CSI presterar sämre. Progressionen mellan studierna visar att RSSI med statisk featureextraktion är fullt tillräckligt för binär närvarodetektering, medan CSI möjliggör mer detaljerad aktivitetsklassificering till priset av mer avancerad signalbehandling.

En gemensam egenskap hos de granskade systemen är att de är device-free, personer som detekteras behöver inte bära någon enhet. Flera studier framhåller även att tekniken är integritetsbevarande eftersom radiosignaler inte kan generera bilder eller identifiera individer (Li et al. 2022; Miao et al. 2025). Dessa egenskaper gör tekniken lämpad för tillämpningar där personuppgiftsbehandlings ska minimeras. Enligt GDPR artikel 5.1(c) ska personuppgifter vara lämpliga, relevanta och inte för omfattande till ändamålet, principen om uppgiftsminimering (Europaparlamentet och rådet, 2016). Ett WiFi baserat system som enbart registrerar signalförändringar, utan möjlighet att identifiera eller spåra enskilda personer, uppfyller detta krav genom design. Detta skiljer sig kraftigt från kamerabaserade system, som samlar in betydligt mer data än vad som krävs för binär närvarodetektering och därmed kräver mer omfattande rättslig grund och tekniska skyddsåtgärder.

## **2.3 Kunskapslucka**

Litteraturen visar att WiFi baserad närvarodetektering med befintliga IoT-enheter uppnår 83-99% precision beroende på signaltyp och antal klasser. Flertalet studier använder dock specialiserad hårdvara (SDR- plattformar, modifierade OpenWrt-routrar) eller kräver CSI-rapportering. Färre studier undersöker möjligheten att använda RSSI-data från helt omodifierade, kommersiellt tillgängliga smarta uttag, såsom Shelly Plus Plug S i kombination med en anomalidetekterande modell som Isolation Forest och en kamerasensor som ground truth under träning. Mrazovac et al. (2012) identifierar att precisionen sjunker i större rum med positioner bortom nodernas räckvidd, men tar inte upp rumsliga strategier som positionell viktning av flera ankare. Detta utgör ett område där den publicerade forskningen idag är begränsad.

## 3. METOD

### 3.1 Undersökningsdesign

Arbetet är upplagt som en empirisk fältstudie i en aktivt använd universitetslabbsal. I stället för att utvärdera närvarodetektion under kontrollerade laboratorieförhållanden samlades data in i en sal som användes normalt under hela perioden med föreläsningar, grupparbete, städning och passerande trafik i korridoren utanför. Valet är medvetet: de felkällor som en verklig installation möter (brusiga RSSI-värden, drift i signalnivåer mellan dygn, möbler som flyttas efter föreläsningar) ingår därmed i datamaterialet i stället för att kontrolleras bort, vilket gör resultaten mer representativa för en faktisk driftsituation.

Studien följer en iterativ ansats. En mätuppställning installerades, RSSI-data samlades in kontinuerligt, en detektionsmodell utvecklades och utvärderades offline mot insamlad data, och de slutsatser utvärderingen gav återfördes till modellens utformning. Modellen driftsattes därefter på plats för att verifiera att den fungerar i realtid.

### 3.2 Mätuppställning och hårdvara

Systemet bygger uteslutande på konsumenthårdvara som fanns tillgänglig vid projektstart. En Asus RT-AC52U\_B1-router placerades centralt i salen för att ge så symmetrisk signaltäckning som möjligt mot rummets olika delar, och fixerades därefter för att inte introducera drift under mätperioden. Routern kördes med tillverkarens ordinarie firmware utan modifiering.

Runt om i salen placerades fem IoT enheter av tre olika fabrikat (Shelly, Cleverio och Prokord), vart och ett anslutet till routerns WiFi-nät. Uttagen fungerar som stationära referensankare: eftersom de inte rör sig speglar förändringar i signalstyrkan mellan ett ankare och routern förändringar i den fysiska miljön mellan dem. Ett av ankarna sitter intill routern, övriga är fördelade mot rummets hörn och längs väggarna. Ytterligare en enhet, en Shelly H&T-sensor, fanns i salen men visade sig ge betydligt mer instabil signal än uttagen och uteslöts ur modellen. En Raspberry Pi med Home Assistant fungerade som central nod i det lokala nätverket och ansvarade för datainsamling, modellinferens och automation. En Reolink RLC-410W-kamera installerades i rent rörelsedetekteringsläge (ingen video spelades in eller lagrades) och användes enbart för att generera referensdata under valideringen (avsnitt 3.4). All hårdvara kommunicerade på det lokala nätverket; ingen rådata lämnade nätet (avsnitt 3.7).

### 3.3 Datainsamling

Datainsamlingen byggdes kring en bärande princip: i stället för att läsa signalstyrka från varje smart uttag var för sig används routern som en enda, gemensam mottagare. Eftersom samtliga ankare är anslutna till samma router speglar routern hur stark signal den tar emot från var och en av dem. Det ger en enhetlig mätpunkt med samma radiochip och samma kalibrering för alla ankare, oberoende av enheternas fabrikat ett Shelly-uttag och ett Tuya-uttag mäts på exakt samma sätt.

En insamlingstjänst på Raspberry Pi:n anslöt till routern via dess administrativa gränssnitt (SSH) var tionde sekund. Att direkt läsa ut signalstyrka per ansluten klient visade sig dock inte vara möjligt då routerns ordinarie firmware exponerar inte någon tillförlitlig tabell över signalstyrka per klient. Insamlingen löstes därför med en metod som fungerar trots denna begränsning. Routern håller ett globalt värde för signalstyrkan på den senast mottagna radoramen. Genom att i tur och ordning pinga en bestämt ankare och omedelbart därefter läsa

av routerns senast mottagna värde fångas just det ankarets signalstyrka. Proceduren upprepas för varje ankare vid varje mätning. Routern rapporterar signalstyrkan per antenn, och ett medelvärde över de aktiva antennerna används.

Metoden har en känd felkälla: om en annan enhet skickar trafik i tidsglappet mellan ping och avläsning registreras fel värde. På ett förhållandevis tyst nät inträffar detta sällan, och kvarvarande felaktiga utslag dämpas av att den efterföljande analysen arbetar med rullande medianvärden snarare än enskilda mätningar. Att insamlingen behövde utformas på detta sätt är i sig en konsekvens av designvalet att inte modifiera någon hårdvara och samtidigt en demonstration av att metoden går att genomföra med utrustning exakt som den levereras.

Varje mätning skrevs som en rad per ankare till en daglig logg fil lokalt på Raspberry Pi:n, med tidsstämpel, ankarnamn, uppmätt signalstyrka och kamerans aktuella tillstånd. Ingen rådata lämnade det lokala nätverket. Insamlingen pågick sammanhängande från den 28 april till och med den 17 maj 2026. Eftersom salen användes normalt under hela perioden innehåller materialet både tomma nätter och helger och en bred variation av faktisk användning.

### 3.4 Annotering och ground truth

För att kunna avgöra om modellens beslut var korrekta krävdes ett oberoende facit. Två nivåer av referensdata användes. Dels taggades varje RSSI-mätning automatiskt med kamerans aktuella tillstånd (bemannat eller tomt), vilket ger en grov men kontinuerlig etikett. Dels identifierades och dokumenterades nio kända närvarofönster manuellt, där antalet personer i salen noterades från ett ensamt stillasittande person till en föreläsning med 20–30 deltagare. Dessa annoterade fönster utgör en striktare facit än kameran och användes som primärt underlag vid utvärderingen av modellens träffsäkerhet.

### 3.5 Detektionsmodell och träning

Detektionsmodellen kombinerar två kompletterande angreppssätt. Ett regelbaserat lager fångar tydliga, väntade signaturer av närvaro exempelvis ett bestående fall i signalstyrkan på ankaret närmast routern. Ett maskininlärningslager i form av en Isolation Forest fångar mer subtila eller oväntade avvikelser som regler inte täcker. Inför varje beslut jämförs aktuella mätvärden mot en adaptiv referensnivå som långsamt följer miljöns naturliga drift under tomma perioder, så att modellen skiljer verklig närvaro från gradvisa förändringar i rummet.

Isolation Forest-modellen tränades enbart på data från tider då salen med säkerhet var tom, i första hand helgen 1–3 maj. Två träningsstrategier jämfördes enbart helgdata respektive helgdata kompletterad med nattetid på vardagar och den variant som gav bäst utvärderingsresultat valdes (se avsnitt 4). Eftersom modellen tränas uteslutande på tom-data behövs ingen annoterade närvarodata för själva träningen; de annoterade fönstren används enbart vid utvärdering.

### 3.6 Utvärdering

Modellen utvärderades offline genom att den kördes mot insamlad historisk data, vilket gör att olika modellversioner och tröskelvärden kan jämföras mot exakt samma material. Tre former av utvärdering användes:

Annoterade närvarofönster. Modellen kördes mot de nio manuellt dokumenterade fönstren. Mätvärden var dels om perioden överhuvudtaget detekterades (sann-positiv-rate), dels hur lång tid det tog innan den detekterades (detektionslatens).

Falska perioder under tomhelg. Modellen kördes mot helgdata då salen var bekräftat tom, och antalet felaktigt flaggade närvaroperioder räknades.

Null-empty-test. För varje natt under mätperioden analyserades ett tvåtimmarsfönster mellan 02:00 och 04:00, då fysisk närvaro är utesluten. Testet användes för att mäta hur ofta enskilda ankare respektive flera ankare samtidigt ger falska utslag, och därmed motivera kravet på samstämmighet mellan flera ankare.

Tre mått på sann-positiv-rate redovisas i resultatkapitlet, eftersom de tillsammans ger en mer komplett bild än vad något av dem ger ensamt. Sample-TPR är andelen RSSI-sampel som flaggades som närvaro under annoterad närvaro. Fönster-TPR är andelen annoterade närvarofönster som fångades alls. Kamera-TPR är andelen längre kamerahändelser (3 minuter eller längre) som fångades. Sample-TPR är det balanserade enskilda måttet, medan fönster-TPR är strikt (vi har medvetet valt svåra stillasittande gränssfall till de annoterade fönstren) och kamera-TPR är brett, eftersom kameran utlöses av rörelse och därför främst fångar rörelse.

### **3.7 Live-drift och dataflöde**

Efter att utvärderingen gett tillfredsställande resultat driftsattes systemet på Raspberry Pi:n den 13 maj 2026. I drift loggas varje mätning lokalt tillsammans med modellens beslut, vilket möjliggör retrospektiv felsökning. Till Azure IoT hub vidarebefordras två typer av händelser. Realtidsförändringar i rumsstatus (lampa tänds eller släcks) samt aggregerade närvaroperioder med start, slut och varighet när en period avslutas. För att Power BI visualiseringen ska vara korrekt utan att rådata behöver skickas, skickas dessutom ett keepalive-medelande var femte minut med aktuellt rumsstatus, utan detta blir graferna i Power BI ojämna på grund av långa dataluckor. Rå RSSI-data, kamerans rörelsedata och modellens inträna tillstånd stannar lokalt på Raspberry Pi:n. Datautflödet till molnet uppgår därmed till under en megabyte per dygn, vilket är en konkret tillämpning av principen om dataminimering.

### **3.8 Användning av AI-verktyg**

AI-verktyg har använts som stöd i delar av arbetet, både i kodutvecklingen och i skrivprocessen. I detta avsnitt redovisar vi öppet var och hur verktygen har använts. Minst lika viktigt är vilka kontroller vi själva har byggt in för att säkerställa att det som hamnar i rapporten är vårt eget.

För kodutvecklingen användes Claude Code (Anthropic) som assisterande verktyg. Det bidrog till att ta fram Python-skript för RSSI-loggning via SSH mot routern, träning av Isolation Forest-modellen, offline-utvärdering, samt analys- och visualiseringsskript. AI-genererade analyskript användes dessutom för att sammanställa tabeller över signalmönster, exempelvis baseline-nivåer per ankare och hur RSSI skiftade under bemannade perioder, som låg till grund för våra val av tröskelvärden och regler i modellen. Parallellt med varje sådan körning inspekterade vi den underliggande rådatan själva för att försäkra oss om att skriptens utdata speglade vad som faktiskt fanns i loggarna. Alla designval (val av features, tröskelvärden, modellarkitektur, utvärderingsstrategi och systemarkitektur) är våra egna beslut, grundade på det empiriska materialet och löpande diskussioner i gruppen.

AI har även använts som språkligt stöd i skrivprocessen, för att strukturera avsnitt, omformulera meningar och föreslå förbättrad svenska. Allt sakinnehåll, alla resonemang, alla slutsatser och

samtliga numeriska resultat är våra egna och baseras på den datainsamling och de analyser som beskrivs i den här rapporten. Referenser till tidigare forskning är manuellt verifierade mot originalkällorna och har inte hämtats direkt från AI-genererad text.

AI-genererad kod är inte fri från fel. Modellen kan blanda ihop API:er, hallucinera funktioner eller missförstå avsikten, och vi har därför byggt in flera lager av kontroll. Nya skript testades först på korta tidsfönster (ett enskilt dygn, därefter en helg) innan de släpptes på hela mätperioden, vilket gjorde det möjligt att snabbt upptäcka uppenbara fel utan att vänta på att en flera timmar lång körning skulle bli klar. Numeriska utdata jämfördes manuellt mot rådata-CSV:erna. Exempelvis kontrollerade vi att summan av detekterade närvarominuter en given dag stämde överens med vad rådatats kameralabel visade. För de annoterade närvarofönstren läste vi själva rå RSSI-data sida vid sida med kamerans rörelse-events och kunde bekräfta att de stämde: när kameran flaggade rörelse syntes motsvarande mönster i RSSI:n, med tydliga skiften upp eller ner från nattens baseline. Det är denna direkta avläsning av rådata som ger en oberoende referenspunkt mot modellens utdata. Centrala siffror i rapporten (sample-TPR, antal fångade fönster, periodlängder, detektorbidrag) reproducerades genom att vi körde hela kedjan från råa loggar till sammanställning flera gånger, både under utvecklingen och vid ett sista frysta tillstånd.

Uppgiftens tidsram (cirka 3 veckor från projektstart till rapportinlämning) hade inte räckt för det projekt vi genomfört om all kod skulle ha skrivits från grunden manuellt. AI-verktyget tog fram förslag och första utkast till det repetitiva arbetet (uppsättning av loggningsskript, parsing av routerutdata, bearbetning och sammanslagning av CSV-filerna och plottning för visuell felsökning), som vi sedan implementerade i systemet, körde och testade. Det frigjorde tid till de delar där människans omdöme är avgörande: experimentdesign, tolkning av signalmönster, valideringsstrategi, och den löpande granskningen av att resultaten faktiskt stämmer. AI har varit en möjliggörare för att vi inom en kort tidsram skulle hinna både bygga, validera och dokumentera systemet, men inte en ersättare för forskningsmetodik. Slutligt ansvar för rapportens innehåll och påståenden ligger hos oss som författare.

## 4. RESULTAT

### 4.1 Utvärderings uppställning

Den modell som var i drift vid mätpunktens slut kördes offline mot hela periodens RSSI-loggar, 164 631 sampelpunkter över 20 dygn. Hela perioden utvärderas därmed som om det slutgiltiga systemet hade varit igång sedan början. Återuppspelningen använder exakt samma detektor och modellkod som körs på Raspberry Pi:n, vilket säkerställer att resultaten stämmer överens med den verkliga driften.

Detektionsmåttan beräknas på fönstret 30 april-16 maj, med de fyra dygn som ingick i modellens träningsdata (2, 3, 9 och 10 maj) uteslutna, alltså 13 oberoende dygn. Som facit används dels de nio manuellt anmarkerade närvarofönster (avsnitt 3.4), dels kamerans rörelsedetektering.

### 4.2 Detektionsförmåga

| Mått                                           | Värde                                                      |
|------------------------------------------------|------------------------------------------------------------|
| Sann-positiv-rate (sattel-TPR)                 | 67,8 % (1 421 av 2 096 sampel. 349 min anmarkerad närvaro) |
| Fågade närvarofönster                          | 4 av 9 anmarkerade fönster                                 |
| Detektionslatens mot anmarkering               | median 2,6 min, max 34,7 min                               |
| Kamerarörelse, långa händelser ( $\geq 3$ min) | 28 av 43 fågade (65 %)                                     |

Modellen fågar aktiv närvaro genomgående, men inte felfritt. Av de fyra fågade fönstren detekterades två med 0 minuters latens, ett efter 5,2 minuter och ett först efter 34,7 minuter. De fem fönster som missades enligt referensdata skiljer sig i karaktär från de övriga, mönstret är att modellen har svårt att fåga personer som sätter sig stilla utan mycket rörelse alls.

| Fönster                                     | Kameran under fönstret           | Modellen under fönstret |
|---------------------------------------------|----------------------------------|-------------------------|
| 2026-05-04_2P (12:08-12:30)                 | Detekterar rörelse               | Tänder ej               |
| 2026-05-05_2p_stilla (09:57-10:30)          | Ingen rörelse                    | Tänder ej               |
| 2026-05-05_1p_stilla (09:14-09-25)          | Detekterar rörelse               | Tänder ej               |
| 2026-05-05_2p_mindre rörelser (09:30-09:39) | Detekterar rörelse               | Tänder ej               |
| 2026-04-30_1p_stilla (11:42-12:02)          | Väldigt lite rörelse (4 sampels) | Tänder ej               |

Av de fem fönster som missades enligt referensdata följer fyra ett tydligt mönster, stillasittande sessioner där en eller flera personer satt utan att generera särskilt mycket rörelse, vilket är just den typ av närvaro WiFi-RSSI har svårast att fåga. Det femte fönstret (2026-05-04\_2p) skiljer sig från de andra: kameran registrerade sammanhängande rörelse från 12:15 till 14:35, alltså

väl in i fönstret och flera timmar därefter, medan modellen tände först 12:43, tretton minuter efter fönsterkanten. Den sena tändningen tyder på en ändring i aktivitetsmönstret vid den tidpunkten, exempelvis ökad rörelse eller en förflyttning i rummet som gav modellen en tydligare signal att reagera på. Missen handlar därför om hur snabbt modellen reagerar på lågintensiv aktiv närvaro i svåra signalförhållanden snarare än om en blindhet för närvaro överhuvudtaget. Sann-positiv-raten på sampelnivå, 67,8 %, ska tolkas mot denna bakgrund: den dras ned av de stillasittande fönstren, medan aktiv närvaro fångas nära fullständigt.

### 4.3 Falsklarm

| Testperiod                             | Längd | Falsklarm                      |
|----------------------------------------|-------|--------------------------------|
| Nattvakuum 02:00–04:00 (samtliga dygn) | 38 h  | 0,00 % — inga perioder         |
| 1 maj 06:00–22:00 (tom helgdag)        | 16 h  | 3,06 % på sampelnivå, 1 period |

En nattspärr (natt-guard) gör systemet helt tyst mellan 00:00 och 05:00 över samtliga 20 dygn. Under tomma dagtimmar förekommer korta falska perioder, de flesta sorteras bort med hjälp av femminuters längdfilter som tillämpas innan perioder loggas (avsnitt 4.6).

### 4.4 Detektorernas bidrag

Modellens fyra detektorer (A (median-shift), B (mult ankar variation), C (mikrorörelse) och D (Isolation Forest-anomali) bidrar ojämnt.

|                    | A   | B    | C   | D    | Enbart latch |
|--------------------|-----|------|-----|------|--------------|
| Tänder perioden    | 0 % | 21 % | 8 % | 72%  | —            |
| Aktiv under på-tid | 6 % | 2 %  | 3 % | 41 % | 50 %         |

Anomalidetektorn D är modellens främsta faktor, den tänder 72 % av perioderna och ensam aktiv detektor under 41% av på-tiden. Regeldetektorn B fångar aktiva ankomster och svarar för 21% av tändningarna, men eftersom rörelse vid ankomst är kortvarig är B bara aktiv 2% av tiden. Den regelbaserade mediandetektorn A bidrog inte till någon tändning under utvärderingsperioden. Ungefär halva på tiden hålls av latch mekanismen utan att någon detektor är aktiv, den fyller de glapp som uppstår när en stillasittande person tidvis inte genererar någon signal.

### 4.5 Effekt av baseline-drift-åtgärden

Den återkopplingsdrift i baselinen som beskrivs i avsnitt 5.1 (fråga 4) åtgärdades den 13 maj. Åtgärden hade tydlig effekt:

|                          | Modell på (per dygn)     | Längsta sammanhängande period |
|--------------------------|--------------------------|-------------------------------|
| 13 maj (före åtgärd)     | 838 min (58 % av dygnet) | 469 min — 7,8 h oavbrutet på  |
| 14–16 maj (efter åtgärd) | 24–69 min                | ≤ 17 min                      |

Den nya nattliga baselinen, tillsammans med nattspärren, eliminerade det tidigare beteendet där modellen kunde fastna i på-läge i timmar (när det med största sannolikhet inte är någon i labbsalen).

## 4.6 Närvaroperioder och tidsbias

Närvarologgens tidsstämplar visar när systemet upptäckte respektive tappade en person, inte exakt när personen kom och gick. Tre saker påverkar hur perioderna ska tolkas.

**Periodslut.** Modellens närvarosignal släpar tolv minuter efter den sista detektoraktiviteten (latch 10 min plus cooldown 2 min). Närvarologgen avslutar därför perioden vid sista detektoraktivitet plus 2 minuter. Över hela utvärderingsfönstret ger det

| Periodmått (30/04 till 16/5) | Total På-tid |
|------------------------------|--------------|
| Modellens råa närvarosignal  | 4 436 min    |
| Loggat värde (53 perioder)   | 3 449 min    |

**Periodstart.** Den loggade starten ligger efter att personen faktiskt kom in. Teoretiskt handlar det om mellan 0,5 minuter (detektor B) och 2,7 minuter (detektor D), och i praktiken är medianfördröjningen 9,2 minuter mätt mot kamerans rörelseevents.

**Periodantal.** Latchen håller ihop en period även när rörelsen gör uppehåll på upp till tio minuter. Vid längre stillhet avslutas perioden, och då kan en och samma vistelse delas upp i flera. De 53 loggade perioderna stämmer därför inte exakt med antalet faktiska besök.

Sammantaget visar loggen på ett pålitligt sätt att ett rum användes och ungefär när det skedde, men exakta start och sluttider och antalet perioder har en systematisk osäkerhet.

## 4.7 Täckningsområde

WiFi-RSSI täcker den volym där en kropp skuggar en dominerande signalväg mellan router och ankare. Med routern centralt placerad och fyra hörna ankare bildar de starka signalvägarna fyra "ekrar". En person som sitter stilla mellan ekrarna, vid sidan av en stark väg, ger knappt någon störning.

Döda zoner uppstår där RSSI ekrarna inte når. En person som sitter i en sådan zon är osynlig, vilket är det fall som upptäcktes den 5 maj.

Konsekvensen för hur resultaten ska tolkas. Systemet känner bara av om någon är i det specifika området där utrustning är placerad. Eftersom enheterna är placerade i hörnen av rummen så blir mätningarna bäst nära routern och dödzone blir utmed väggarna.



## 5. DISKUSSION

### 5.1 Svar på frågeställning

#### 5.1.1 Fråga 1

Den första frågan efterfrågade hur väl hybridmodellen klassificerar tomt respektive bemannat, mätt som true positive rate (TPR), antalet falska larm per dygn och detektionsfördröjning.

Utvärderad över 13 oberoende dygn fångade modellen 4 av 9 annoterade närvarofönster samt 28 av 43 fönster upptäckta av kameran (längre än 3 minuter), med en sampel-TPR på 67,8 %. Detektionsfördröjningen mot annoteringen var låg, median 2,6 minuter och som mest 34,7 minuter. Falsklarmen var få, noll under nattperioderna över alla dygn och endast en bekräftad falsk period över hela utvärderingsperioden (1 maj 06:10–06:17).

Siffrorna döljer dock ett mönster som är avgörande för tolkningen. Modellen fångar aktiv närvaro (föreläsningar och rörelse) fullständigt och snabbt, medan fyra av de fem missade fönstren var stillasittande sessioner i en svag signalzon. Det femte fönstret handlade om aktiv närvaro där modellen var sen snarare än blind. TPR på 67,8 % är alltså inte ett jämnt fördelat fel, utan en summering av nära fullständig detektion av aktiv närvaro och utebliven detektion av en specifik, fysikaliskt svår delmängd.

Anomalidetektorn (Isolation Forest) är modellens främsta faktor och tänder majoriteten av perioderna, medan den regelbaserade rörelsedektorn fångar aktiva ankomster snabbt. Den regelbaserade median-dektorn bidrog däremot inte till någon tändning under utvärderingsperioden. Att kombinera ett oöverskådligt anomalilager med regler ger alltså mätbart värde, men alla regler bär inte sin vikt.

#### 5.1.2 Fråga 2

Den andra frågan gäller vilken detektionsfördröjning som krävs för att hålla antalet falska positiva på en acceptabel nivå givet den brusiga RSSI-signalen från konsumenthårdvaran, och hur den fördröjningen påverkar systemets användbarhet för tillbakablickande närvarologgning respektive realtidsstyrning av belysning.

Utvärderingen visar att bruset i RSSI-signalen är den utlösande faktorn. Signalstyrkan fluktuerar av många skäl som inte har med människor att göra, och en modell som reagerar omedelbart på varje avvikelse skulle producera ett oacceptabelt antal falska positiva. För att hålla falsklarmen nere har vi byggt in flera lager av persistens, både ett krav på samstämmighet mellan flera ankare och en latch som håller modellen på när rörelsen tillfälligt avtar. Det ger den låga falsklarmsraten vi vill ha (noll under nattperioderna, cirka en falsk period per dygn på testhelger) men kostar fördröjning. För aktiv närvaro hamnar latensen typiskt på 0–5 minuter, men kan i värsta fall bli 34,7 minuter när signalsignaturen är svag.

Svaret på frågan blir därför att kraven på låg latens och låg falsklarmsrate inte går att lösa samtidigt med den hårdvara projektet bygger på. För realtidsstyrning av belysning är detta diskvalificerande, en lampa som ska tändas direkt när någon kommer in kan inte vänta i flera

minuter på modellens bekräftelse, och tas persistens-filtren bort exploderar i stället falsklarmen. För tillbakablickande närvarologgning är samma avvägning hanterbar, det räcker att veta att rummet användes och ungefär när, och de korta brusperioder som ändå kommer igenom sållas till stor del bort av det femminuters längdfilter som tillämpas innan en period loggas.

### 5.1.3 Fråga 3

Fråga 3 handlar om hur de installerade ankarna skiljer sig åt i signalstabilitet och bidrag till detektionen, och hur skillnader kan kopplas till placering och hårdvara.

Ankare bidrog mycket ojämnt. Ankaret närmast routern (led-slingan) gav den renaste och mest tillförlitliga signalen, en tydlig och ihållande nedgång i signalstyrka när en person satt sig vid samma bord som routern står på, utan att bruset ökade tydligt. Övriga ankare bidrog svagare eller mindre konsekvent, en fungerade mer som en närhetsdetektor, med kraftiga utslag enbart när någon befann sig mycket nära den, en annan var trög och reagerade först flera minuter efter att en person satt sig, en annan var inkonsekvent och bytte beteende beroende på antal personer i rummet. Den separata Shelly H&T-sensorn var så brusig (cirka 15 dB firmware-jitter) att den uteslöts helt ur modellen.

Skillnaderna har med fysisk placering att göra (avstånd till routern och fri sikt mot den aktiva delen av rummet) och hårdvarans känslighet snarare än fabrikat. Det brusigaste uttaget och en av de stabilaste var båda av fabrikatet Shelly, vilket talar emot att märkesval i sig förklarar variationen. Den konkreta illustrationen finns i 4 maj fallet med tre stillasittande personer: ledslings lyfte signalvariationen omkring fem gånger över det tomma rummets nivå, medan de övriga ankarna stannade på två till två och en halv gång. Slutsatsen är att ankarnas placering är minst lika viktig som antal, ett system av den här typen vinner på att ha ett välplacerat primärankare nära den zon där aktiviteten förväntas hända, snarare än enbart många ankare jämnt fördelat.

En ytterligare observation gäller hur signalen från varje ankare bildas. Routern mäter signalstyrkan med två antenner, och modellen använder medelvärdet av dem (avsnitt 3.3). Detta vilar på ett underförstått antagande, att båda antennerna observerar samma närvarosignal. En kort efteranalys av tre annoterade fönster visar att antagandet inte håller för kroppsblockering. Routers två antenner ser delvis olika signalvägar, en kropp som blockerar den ena vägen kan lämna den andra opåverkad, eller till och med förstärkt via reflektion. När så sker skiftar de två antennvärdena åt olika håll, och medelvärdet tar ut en signal som det egentligen borde bevara. I analysen gav medelvärdet det starkaste signal-brus förhållandet i endast 2 av 15 ankar- och fönsterfall. I flera fall, bland annat för bänkankaret prokord\_vh vid en stillasittande person, låg medelvärdets skift på brusnivå medan en enskild antenn visade ett tydligt utslag. Vilken antenn som bär signalen är dock inte konstant, vilket innebär att förbättringen inte ligger i att välja en fast antenn utan i att låta modellen ta emot båda antennvärdena som separata indata. Den nuvarande modellen lämnar med andra ord en del detektionssignal oanvänd. Att detta över huvud taget kunde upptäckas berodde på att båda antennvärdena loggades från början, även om bara medelvärdet användes i modellen.

### 5.1.4 Fråga 4

Fråga 4 gäller i vilken utsträckning systemets prestanda påverkas av miljöförändringar i en aktivt använd sal, och hur väl en adaptiv baseline kompenserar för det.

Signalnivåerna visade sig drifta flera dB mellan dygn trots att ingen hårdvara flyttades. Driften kunde kopplas till möblering, när en stol eller dylikt flyttades under en session och blev kvar i nytt läge förnedrades signalvägarna mätbart. Under helger, då rummet inte användes, var signalen däremot mycket stabil. Den adaptiva baselinen, som långsamt följer rummets signalnivå under tomma perioder, kompenserar väl för denna drift utan att behöva manuell omkalibrering. Den löser däremot inte möbelflytt under pågående session, fram till nästa gång rummet är tomt är baselinen inaktuell. Detta accepteras som ett känt och dokumenterat fel, eftersom kraftig ommöblering främst sker efter större föreläsningar.

Ett mer subtilt problem framkom under utvecklingen. Baseline som uppdateras kontinuerligt med hjälp av modellens egen bedömning av att rummet är tomt riskerar en återkopplingsslinga, under en lång session med en stillasittande person migrerar baselinen sakta mot personens egen signalprofil, och modellen tappar då detektion. Problemet åtgärdades genom att överge den kontinuerliga uppdateringen till förmån för en baseline som räknas om en gång per natt, från en period då rummet säkert är tomt, och som sedan hålls fryst under dagen. En kontrollregel infördes dessutom som tvingar systemet att släppa närvarostatusen om rummet flaggats som bemannat ovanligt länge utan att de rörelsebaserade detektorerna bekräftade det. Svaret på frågan är därför tudelat, en adaptiv baseline hanterar drift mellan dygn väl, men en osäker självrefererande uppdatering är inte säker, en mer säker nattvis strategi krävdes. Effekten av omläggningen redovisas i resultat: modellens tid i på-läge minskade från 838 minuter över ett dygn före åtgärden till mellan 24 och 69 minuter per dygn (detta var på helgdagar).

## 5.2 Slutsats

Arbetets syfte var att utveckla och utvärdera ett närvaodetektering som detekterar mänsklig närvaro i en labbsal genom RSSI förändringar från befintliga, omodifierade WiFi enheter, konstruerat enligt principen privacy by design. Studien visar att detta är möjligt att en hybridmodell av regelbaserad detektion och anomalidetektion, matad med RSSI från en uppsättning omodifierade konsumentenheter via en gemensam router, kan skilja en bemannad sal från en tom, och göra det utan att vare sig bild eller ljudmaterial samlas in. Modellens ofullständiga täckning av stillasittande närvaro gör den bäst lämpad för tillbakablickande närvarologgning snarare än för realtidsstyrning av belysning. LED-slingan behålls dock som ett lokalt direkt avläsbart funktionsbevis.

För fastighetsförvaltning och lokalplanering ger en närvarologg ett datadrivet underlag för hur ofta och när lokaler faktiskt används, vilket kan ligga till grund för schemaläggning och bättre nyttjande av befintliga ytor, och tack vare Azure pipelinen kan underlaget följas på distans utan att rådata lämnar lokalen. För energieffektivisering kan historiska närvaromönster användas för att styra belysningen och ventilation efter faktiskt behov. För integritetsmedvetna verksamheter erbjuder lösningen ett alternativ till kameror som samlar in väsentligt mindre persondata, vilket sänker kraven på rättslig grund och tekniska skyddsåtgärder. Och eftersom lösningen bygger på billig och redan installerad hårdvara blir den tillgänglig även för mindre organisationer. Det samhällsklimat av ökad integritetsmedvetenhet och växande IoT-täthet som beskrivs i inledningen gör en sådan lösning relevant. Den möter behovet av att förstå hur lokaler används utan att öka mängden av insamlade persondata.

## 5.3 Vidare forskning

Resultaten öppnar för flera möjliga forskningsriktningar. En enkel förbättring, som kan prövas direkt på redan insamlad data, är att mata in routerns två antennvärden som separata indata i

stället för deras medelvärde. Som diskuterats i avsnitt 5.1 (fråga 3) tar medelvärdet i vissa fall ut en närvarosignal som en enskild antenn fångar tydligt. Eftersom båda antennvärdena redan finns i de insamlade loggarna krävs ingen ny datainsamling för att utvärdera detta.

En naturlig vidareutveckling vore att ersätta RSSI med CSI, som beskriver amplitud och fas på varje underbärare i WiFi signalen och därmed erbjuder rikare kanalinformation. Natarajan, Krishnasamy och Singh (2024) visar att CSI från samma typ av ESP32 plattform möjliggör klassificering av fyra aktivitetsklasser med 83,39 % precision, jämfört med den binära detektionen som RSSI baserade system erbjuder. En övergång till CSI skulle kunna göra det möjligt att skilja mellan exempelvis sittande arbete och rörelse i rummet, och därmed möjliggöra mer specifik styrning av belysning och ventilation baserat på aktivitetstyp snare än enbart närvaro.

En annan riktning är att övergå från oövervakad anomalidetektion (Isolation Forest) till övervakad klassificering, exempelvis Random Forest. Medan Isolation Forest enbart svarar på frågan ”är det normalt eller avvikande?”, kan en övervakad modell tränas att särskilja positioner inom rummet, exempelvis vilket bord en person sitter vid. Natarajan, Krishnasamy och Singh (2023) visar att centralitetsbaserade RSSI features (median, medelvärde) är rumsspecifika snare än närvarospecifika, vilket tyder på att positions placering inom ett rum är möjlig med befintliga signaldata. En sådan förmåga skulle kunna användas för att styra belysningen för specifika delar av rummet, där enbart den del av rummet som är bemannat är belys.

Systemet i sin nuvarande form svarar binärt (rummet är tomt eller bemannat) utan att säga antal personer i rummet. Flerpersonsdetektion är ett mycket svårare problem, eftersom RSSI förändringar från flera personer inte enkelt kan separeras. Zou, Zhou, Yang och Spanos (2018) uppnår 92,8 % precision vid personräkning med CSI-data, men deras system kräver OpenWrt-routrar. Huruvida RSSI features från omodifierade enheter innehåller tillräckligt med information för att skilja mellan olika antal personer är något som man hade kunna undersöka vidare.

Slutligen har modellen i denna studie tränats och utvärderats i ett specifikt rum med en viss planlösning och möblering. Huruvida den fungerar i andra rum med annorlunda geometri, byggnadsmaterial och antalet accesspunkter är en öppen fråga. Mrazovac et al. (2012) visar att precisionen sjunker från 98 % till 84 % när rumsstorleken ökar, vilket tyder på att rumsspecifika faktorer har en stor påverkan. En framtida studie skulle kunna undersöka transferinlärning, där en modell förtränad i ett rum finjusteras med kortare datainsamling i ett nytt rum, för att minska den tid och de arbete som krävs vid varje ny installation.

## 6. REFERENSER

Europaparlamentet och rådet (2016). Förordning (EU) 2016/679 av den 27 april 2016 om skydd för fysiska personer med avseende på behandling av personuppgifter och om det fria flödet av sådana uppgifter, och om upphävande av direktiv 95/46/EG (allmän dataskyddsförordning). Europeiska unionens officiella tidning, L 119, ss. 1–88.

Li, W., Vishwakarma, S., Tang, C., Woodbridge, K., Piechocki, R. J. och Chetty, K. (2022) 'Using RF Transmissions From IoT Devices for Occupancy Detection and Activity Recognition', *IEEE Sensors Journal*, 22(3), ss. 2484–2495. doi: 10.1109/JSEN.2021.3134895.

Miao, F., Huang, Y., Lu, Z., Ohtsuki, T., Gui, G. och Sari, H. (2025) 'Wi-Fi Sensing Techniques for Human Activity Recognition: Brief Survey, Potential Challenges, and Research Directions', *ACM Computing Surveys*, 57(5), Artikel 107. doi: 10.1145/3705893.

Mrazovac, B., Bjelica, M. Z., Kukolj, D., Todorović, B. M. och Samardžija, D. (2012) 'A Human Detection Method for Residential Smart Energy Systems Based on Zigbee RSSI Changes', *IEEE Transactions on Consumer Electronics*, 58(3), ss. 819–824. doi: 10.1109/TCE.2012.6311323.

Natarajan, A., Krishnasamy, V. och Singh, M. (2023) 'Device-Free Human Motion Detection Using Single Link WiFi Channel Measurements for Building Energy Management', *IEEE Embedded Systems Letters*, 15(3), ss. 153–156. doi: 10.1109/LES.2022.3214333.

Natarajan, A., Krishnasamy, V. och Singh, M. (2024) 'Design of a Low-Cost and Device-Free Human Activity Recognition Model for Smart LED Lighting Control', *IEEE Internet of Things Journal*, 11(4), ss. 5558–5567. doi: 10.1109/JIOT.2023.3308219.

Zou, H., Zhou, Y., Yang, J. och Spanos, C. J. (2018) 'Device-free occupancy detection and crowd counting in smart buildings with WiFi-enabled IoT', *Energy and Buildings*, 174, ss. 309–322. doi: 10.1016/j.enbuild.2018.06.040.

## 7. BILAGOR

Kodbas och loggbok: <https://github.com/woltrananton/Integrity-preserving-presence-detection-with-WiFi-RSSI->



HÖGSKOLAN  
I BORÅS

Besöksadress: Allégatan 1 · Postadress: 501 90 Borås · Tfn: 033-435 40 00 · E-post: [registrator@hb.se](mailto:registrator@hb.se) · Webb: [www.hb.se](http://www.hb.se)